

PHÂN TÍCH VÀ PHÂN CỤM KHÁCH HÀNG THỂ TÍN DỤNG

Ứng dụng Khai Phá Dữ Liệu và Học Máy

Báo Cáo Môn Học: Khai Phá Dữ Liệu

Ngày 6 tháng 3 năm 2026

TRANG NHẬN XÉT CỦA GIẢNG VIÊN

Tên sinh viên: Nguyễn Đức Mạnh

Mã sinh viên: 23010902

Lớp học phần: Khai phá dữ liệu-1-2-25(N01)

Nhận xét chung:

Điểm số: _____

Chữ ký giảng viên: _____

Ngày: _____

Mục lục

Lời cảm ơn	8
Tóm tắt	9
1 GIỚI THIỆU	10
1.1 Tổng quan vấn đề	10
1.2 Mục tiêu của báo cáo	10
1.3 Phạm vi của báo cáo	11
1.4 Cấu trúc báo cáo	11
1.5 Những đóng góp chính	12
2 TỔNG QUAN TÀI LIỆU	13
2.1 Giới thiệu về phân cụm (Clustering)	13
2.2 Các phương pháp phân cụm chính	13
2.2.1 Phân cụm dựa trên khoảng cách (Distance-based Clustering)	13
2.2.2 Phân cụm phân cấp (Hierarchical Clustering)	14
2.2.3 Phân cụm dựa mật độ (Density-based Clustering)	15
2.3 Xác định số cụm tối ưu	15
2.3.1 Phương pháp Elbow (Elbow Method)	15
2.3.2 Chỉ số Silhouette (Silhouette Score)	16
2.4 Giảm chiều dữ liệu: Principal Component Analysis (PCA)	16
2.5 Phân cụm khách hàng trong ngành tài chính	17
2.6 Trình trạng công nghệ hiện tại	17
3 PHƯƠNG PHÁP	18
3.1 Quy trình phân tích tổng thể	18
3.2 Dữ liệu sử dụng	18
3.2.1 Nguồn dữ liệu	18
3.2.2 Mô tả dữ liệu	19
3.3 Kỹ thuật xử lý dữ liệu	19

3.3.1	Kiểm tra giá trị thiếu (Missing Values)	19
3.3.2	Phép biến đổi logarit (Log Transformation)	20
3.3.3	Chuẩn hóa dữ liệu (Standardization)	20
3.4	Giảm chiều dữ liệu	20
3.4.1	Tại sao cần giảm chiều?	20
3.4.2	Áp dụng PCA	21
3.5	Xác định số cụm tối ưu	21
3.5.1	Phương pháp Elbow	21
3.5.2	Chỉ số Silhouette	22
3.6	Phân cụm K-means	22
3.6.1	Thuật toán K-means	22
3.6.2	Khởi tạo K-means	22
3.7	Xác thực kết quả phân cụm	22
3.7.1	So sánh với phân cụm phân cấp	22
3.7.2	Phát hiện dị biệt bằng DBSCAN	23
3.8	Phân tích và đặc trưng cụm	23
3.9	Công cụ và môi trường	23
4	XỬ LÝ DỮ LIỆU	25
4.1	Tổng quan bước xử lý dữ liệu	25
4.2	Chẩn đoán chất lượng dữ liệu ban đầu	25
4.2.1	Kích thước và loại dữ liệu	25
4.2.2	Phát hiện giá trị thiếu	26
4.3	Xử lý giá trị thiếu	26
4.3.1	Chiến lược điền (Imputation)	26
4.3.2	So sánh các phương pháp	27
4.3.3	Kết quả sau khi điền	27
4.4	Loại bỏ và xử lý dữ liệu không cần thiết	27
4.4.1	Xóa CUST_ID	27
4.5	Phép biến đổi dữ liệu	28
4.5.1	Tại sao cần biến đổi logarit	28
4.5.2	Áp dụng log transformation	28
4.6	Chuẩn hóa dữ liệu	28
4.6.1	Vấn đề thang đo (Scaling Problem)	28
4.6.2	StandardScaler	29
4.6.3	Nguyên tắc Fit và Transform	29
4.7	Thống kê mô tả sau xử lý	29
4.8	Kiểm tra trùng lặp	30

4.9	Tạm kết luận về xử lý dữ liệu	30
5	PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)	31
5.1	Mục tiêu EDA	31
5.2	Thống kê mô tả các biến chính	31
5.3	Phân tích hành vi tài chính tổng quan	32
5.3.1	Hành vi chi tiêu và thanh toán	32
5.3.2	Hành vi rút tiền mặt	32
5.4	Tương quan giữa các biến	32
5.5	Kiểm tra điều kiện cho phân cụm	33
5.6	Kết luận chương	33
6	KỸ THUẬT VÀ KẾT QUẢ PHÂN CỤM	34
6.1	Giảm chiều dữ liệu bằng PCA	34
6.1.1	Thiết lập PCA	34
6.2	Xác định số cụm tối ưu	35
6.3	K-means với K=4	35
6.3.1	Thiết lập mô hình	35
6.3.2	Đánh giá mô hình	36
6.3.3	Kiểm định độ ổn định của kết quả K-means	36
6.3.4	Quy mô các cụm	37
6.4	Phân tích chi tiết 4 cụm	37
6.4.1	Cụm 0: Khách hàng rủi ro cao	37
6.4.2	Cụm 1: Khách hàng VIP (Premium/VIP Customers)	37
6.4.3	Cụm 2: Khách hàng ít sử dụng	38
6.4.4	Cụm 3: Khách hàng rút tiền mặt	38
6.5	Đối chiếu DBSCAN	38
6.6	Kết luận chương	38
7	THÔNG TIN CHI TIẾT KINH DOANH VÀ KHUYẾN NGHỊ	39
7.1	Phân tích chi tiết các phân khúc	39
7.1.1	Cụm 0: Khách hàng rủi ro cao (High-Risk Customers)	39
7.1.2	Cụm 1: Khách hàng VIP (Premium/VIP Customers)	40
7.1.3	Cụm 2: Khách hàng ít sử dụng (Low-Activity Customers)	41
7.1.4	Cụm 3: Khách hàng rút tiền mặt (Cash Advance Users)	42
7.2	Phân tích DBSCAN (Phân tích giá trị cực trị)	43
7.2.1	Kết quả DBSCAN	43
7.2.2	Giải thích và nhận xét	44

7.2.3	Giá trị cực trị	44
7.3	Khuyến nghị hành động	44
7.3.1	Ngắn hạn (0-3 tháng)	44
7.3.2	Trung hạn (3-6 tháng)	45
7.3.3	Dài hạn (6-12 tháng)	45
7.4	KPI theo dõi	46
8	KẾT LUẬN	47
8.1	Tóm tắt các kết quả chính	47
8.1.1	Về dữ liệu	47
8.1.2	Về phương pháp	47
8.1.3	Về kết quả phân cụm	47
8.1.4	Về giá trị kinh doanh	48
8.2	Các khám phá chính	48
8.2.1	Phân khúc có sự chùng chéo	48
8.2.2	Cụm 1 (Premium/VIP) là nhóm giá trị cao nhất	48
8.2.3	Cụm 2 (Low-Activity) có tiềm năng phát triển cao	49
8.2.4	Cụm 3 (Cash Advance Users) là nhóm rủi ro cao	49
8.3	Hạn chế của nghiên cứu	49
8.3.1	Về dữ liệu	49
8.3.2	Về phương pháp	49
8.3.3	Về giá trị kinh doanh	50
8.4	Hướng phát triển tương lai	50
8.4.1	Cải thiện dữ liệu	50
8.4.2	Cải thiện phương pháp	50
8.4.3	Mở rộng ứng dụng	51
8.4.4	Cải thiện hiệu quả kinh doanh	51
8.5	Ứng dụng thực tế	51
8.5.1	Ngay lập tức	51
8.5.2	Dài hạn	52
8.6	Kết luận cuối cùng	52
A	MÃ NGUỒN PYTHON	53
A.1	Mã đầy đủ cho phân tích	53
A.1.1	Nhập thư viện	53
A.1.2	Bước 1: Tải và xử lý dữ liệu	53
A.1.3	Bước 2: Biến đổi và chuẩn hóa	54
A.1.4	Bước 3: PCA	54

A.1.5	Bước 4: Tìm K tối ưu	54
A.1.6	Bước 5: K-means với K=4	55
A.1.7	Bước 6: Phân tích cụm	56
A.1.8	Bước 7: Phát hiện dị biệt	57
A.1.9	Bước 8: Lưu kết quả	57
A.2	Yêu cầu môi trường	58
A.2.1	Python Version	58
A.2.2	Thư viện cần thiết	58
A.3	Hướng dẫn chạy	58
A.4	Tham khảo mã để tùy chỉnh	58
A.4.1	Thay đổi số cụm	58
A.4.2	Thay đổi tham số DBSCAN	59
A.4.3	Thay đổi số thành phần PCA	59
B	BẢNG DỮ LIỆU CHI TIẾT	60
B.1	Thống kê tổng quan đã xác minh	60
B.2	Hồ sơ chi tiết các cụm K-means (K=4)	60
B.3	Độ đo chất lượng mô hình	61
B.4	Kết quả DBSCAN (đối chiếu)	61
B.5	Thống kê chi tiết 17 biến theo cụm	62
B.5.1	Cụm 0: Khách hàng rủi ro cao (N=1,504)	62
B.5.2	Cụm 1: Khách hàng VIP (N=2,206)	63
B.5.3	Cụm 2: Khách hàng ít sử dụng (N=2,758)	64
B.5.4	Cụm 3: Khách hàng rút tiền mặt (N=2,482)	65
B.6	Ma trận tương quan giữa các biến chính	65
B.7	Thông tin PCA Components	66
B.8	So sánh hiệu suất các phương pháp	67
	Tài liệu tham khảo	68

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành và sâu sắc đến thầy Trịnh Thành, giảng viên môn Khai Phá Dữ Liệu, đã tận tình hướng dẫn, chỉ bảo và tạo điều kiện thuận lợi cho em hoàn thành báo cáo này. Sự giảng dạy chu đáo của thầy đã giúp em nắm vững các khái niệm cơ bản về phân tích dữ liệu, machine learning, và các kỹ thuật clustering. Hơn nữa, thầy luôn khuyến khích em tìm hiểu sâu, thử nghiệm và áp dụng các kiến thức lý thuyết vào thực tế.

Báo cáo này là kết quả của quá trình tìm hiểu, thí nghiệm, và phân tích dữ liệu về phân cụm khách hàng thẻ tín dụng. Thông qua quá trình này, em không chỉ học được cách xử lý dữ liệu, lựa chọn thuật toán phù hợp, mà còn rèn luyện kỹ năng phân tích vấn đề một cách có hệ thống và khoa học.

Em cũng xin ghi nhận những đóng góp quan trọng từ các tài liệu tham khảo quý báu, cũng như sự hỗ trợ của cộng đồng mã nguồn mở. Các công cụ và thư viện như Python, scikit-learn, pandas, numpy và matplotlib đã là những công cụ đắc lực giúp em thực hiện phân tích một cách hiệu quả. Các tác giả của các bài báo khoa học được trích dẫn đã cung cấp nền tảng lý thuyết vững chắc cho báo cáo này.

TÓM TẮT

Báo cáo này trình bày một nghiên cứu toàn diện về phân tích và phân cụm khách hàng thẻ tín dụng. Sử dụng bộ dữ liệu gồm 8,950 khách hàng với 17 biến tài chính, nghiên cứu áp dụng các kỹ thuật khai phá dữ liệu tiên tiến bao gồm:

- Xử lý dữ liệu và phân tích khám phá (EDA)
- Giảm chiều dữ liệu sử dụng PCA
- Phân tích phân cụm K-means với xác định K tối ưu
- So sánh với các phương pháp phân cụm khác (Hierarchical, DBSCAN)
- Phát hiện và phân tích các điểm dị biệt
- Đưa ra các khuyến nghị cho chiến lược tiếp thị

Kết quả phân tích đã xác định được 4 phân khúc khách hàng chính, mỗi phân khúc có các đặc trưng riêng biệt về hành vi chi tiêu, giới hạn tín dụng, dư nợ và tần suất sử dụng.

Từ khóa: Phân cụm, K-means, Khách hàng thẻ tín dụng, Khai phá dữ liệu, Machine Learning

Chương 1

GIỚI THIỆU

1.1 Tổng quan vấn đề

Trong bối cảnh kinh tế toàn cầu hóa, ngành thẻ tín dụng đang phát triển với tốc độ chóng mặt. Các ngân hàng và tổ chức tài chính phải đối mặt với thách thức cấp thiết để hiểu rõ hơn về khách hàng của họ để có thể:

- Phát triển các sản phẩm dịch vụ phù hợp
- Tối ưu hóa chiến lược tiếp thị
- Quản lý rủi ro tín dụng hiệu quả
- Cải thiện tỷ lệ giữ chân khách hàng
- Tăng thu nhập từ các dịch vụ tài chính

Phân cụm khách hàng (Customer Segmentation) là một kỹ thuật quan trọng trong khai phá dữ liệu cho phép các tổ chức nhận diện và hiểu các nhóm khách hàng khác nhau để áp dụng các chiến lược khác nhau.

1.2 Mục tiêu của báo cáo

Mục tiêu chính: Phân tích, phân cụm và đặc trưng hóa các khách hàng thẻ tín dụng để hỗ trợ các quyết định kinh doanh và phát triển chiến lược tiếp thị được cá nhân hóa.

Các mục tiêu cụ thể:

1. **Xử lý dữ liệu:** Làm sạch, chuẩn hóa và chuẩn bị dữ liệu thẻ tín dụng cho phân tích
2. **Khám phá dữ liệu:** Thực hiện phân tích khám phá toàn diện để hiểu đặc điểm của dữ liệu, các phân phối, mối tương quan

3. **Xác định số lượng cụm tối ưu:** Sử dụng các phương pháp như Elbow Method và Silhouette Analysis để xác định K tối ưu
4. **Phân cụm khách hàng:** Áp dụng K-means clustering để phân khúc khách hàng thành các nhóm đồng nhất
5. **Xác thực kết quả:** So sánh kết quả với các phương pháp phân cụm khác (phân cụm phân cấp, DBSCAN)
6. **Phân tích đặc trưng:** Phân tích chi tiết các đặc trưng của từng cụm
7. **Phát hiện dị biệt:** Xác định các khách hàng dị biệt có hành vi khác thường
8. **Đưa ra khuyến nghị:** Đề xuất các chiến lược tiếp thị và kinh doanh dựa trên phân cụm

1.3 Phạm vi của báo cáo

Báo cáo tập trung vào:

- **Dữ liệu:** Bộ dữ liệu công khai về thẻ tín dụng gồm 8,950 khách hàng và 17 biến tài chính
- **Phương pháp:** Các kỹ thuật khai phá dữ liệu không giám sát (unsupervised learning)
- **Công cụ:** Python với các thư viện scikit-learn, pandas, matplotlib, seaborn
- **Khoảng thời gian:** Phân tích dữ liệu tổng hợp (snapshot) từ một thời điểm

1.4 Cấu trúc báo cáo

- **Chương 1 - Giới thiệu:** Tổng quan bài toán, mục tiêu và phạm vi
- **Chương 2 - Tổng quan tài liệu:** Nền tảng lý thuyết cho phân cụm, các phương pháp chính
- **Chương 3 - Phương pháp:** Các kỹ thuật và thuật toán được sử dụng
- **Chương 4 - Xử lý dữ liệu:** Làm sạch dữ liệu, chuẩn hóa, biến đổi
- **Chương 5 - Phân tích khám phá:** Thống kê mô tả, trực quan hóa, phân tích mối tương quan
- **Chương 6 - Kết quả phân cụm:** Áp dụng K-means, xác định K tối ưu, phân tích cụm
- **Chương 7 - Thông tin chi tiết kinh doanh:** Đặc trưng của các cụm, phát hiện dị biệt, khuyến nghị

- **Chương 8 - Kết luận:** Tóm tắt kết quả, hạn chế, hướng phát triển tương lai
- **Phụ lục:** Mã nguồn, bảng dữ liệu chi tiết, đặc tả kỹ thuật

1.5 Những đóng góp chính

- Cung cấp một phương pháp toàn diện cho phân cụm khách hàng thẻ tín dụng
- Xác định được các phân khúc khách hàng có ý nghĩa kinh doanh
- Đưa ra các chiến lược tiếp thị được cá nhân hóa dựa trên phân cụm
- Phát hiện các khách hàng dị biệt có tiềm năng hoặc rủi ro cao
- Cung cấp một mô hình có thể được dùng để phân loại các khách hàng mới

Chương 2

TỔNG QUAN TÀI LIỆU

2.1 Giới thiệu về phân cụm (Clustering)

Phân cụm là một kỹ thuật học máy không giám sát (unsupervised learning) [2] nhằm nhóm các đối tượng dữ liệu thành các cụm một cách sao cho:

- Các đối tượng trong cùng một cụm có sự tương đồng cao nhất
- Các đối tượng ở các cụm khác nhau khác nhau nhất

Phân cụm được ứng dụng rộng rãi trong:

- Phân khúc thị trường (market segmentation)
- Phát hiện cấu trúc dữ liệu
- Nén dữ liệu (data compression)
- Bộ lọc cộng tác (collaborative filtering)
- Phát hiện bất thường (anomaly detection)

2.2 Các phương pháp phân cụm chính

2.2.1 Phân cụm dựa trên khoảng cách (Distance-based Clustering)

K-means:

K-means [12] là một trong những thuật toán phân cụm phổ biến nhất. Phiên bản cải tiến K-means++ [1] giải quyết vấn đề khởi tạo ngẫu nhiên. Thuật toán hoạt động như sau:

1. Chọn ngẫu nhiên K tâm cụm

2. Gán mỗi điểm dữ liệu tới tâm cụm gần nhất
3. Tính toán lại tâm cụm bằng trung bình các điểm trong cụm
4. Lặp lại bước 2-3 cho đến khi hội tụ

Hàm mục tiêu của K-means được định nghĩa là:

$$J = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2 \quad (2.1)$$

Trong đó:

- C_k là cụm thứ k
- μ_k là tâm của cụm thứ k
- K là số lượng cụm

Ưu điểm:

- Đơn giản, dễ hiểu và triển khai
- Nhanh chóng với dữ liệu lớn
- Dễ dàng kết hợp với bộ kỳ vọng-tối đa (EM)

Nhược điểm:

- Phải xác định trước số cụm K
- Nhạy cảm với khởi tạo ban đầu
- Có thể hội tụ tới cực tiểu cục bộ
- Giả định các cụm có hình dạng gần như hình cầu

2.2.2 Phân cụm phân cấp (Hierarchical Clustering)

Phân cụm phân cấp tạo ra một cây phân cấp (dendrogram) của các cụm. Có hai phương pháp chính:

- **Agglomerative (Bottom-up):** Bắt đầu với mỗi điểm là một cụm và liên kết chúng lại
- **Divisive (Top-down):** Bắt đầu với tất cả các điểm trong một cụm và chia chúng ra

Các phương pháp liên kết phổ biến:

- **Single Linkage:** Khoảng cách nhỏ nhất giữa hai cụm
- **Complete Linkage:** Khoảng cách lớn nhất giữa hai cụm
- **Average Linkage:** Khoảng cách trung bình giữa hai cụm
- **Ward Linkage:** Giảm thiểu phương sai [15] (được sử dụng trong báo cáo này)

2.2.3 Phân cụm dựa mật độ (Density-based Clustering)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN [6] nhóm các điểm dựa trên mật độ cục bộ. Các điểm được phân loại thành:

- **Điểm lõi (Core points):** Có ít nhất MinPts điểm khác trong bán kính ϵ
- **Điểm biên (Border points):** Không phải điểm lõi nhưng là hàng xóm của điểm lõi
- **Điểm nhiễu (Noise points):** Không phải điểm lõi cũng không phải điểm biên

Ưu điểm:

- Không cần xác định K trước
- Phát hiện hình dạng cụm tùy ý
- Phát hiện điểm bất thường một cách tự nhiên

Nhược điểm:

- Nhạy cảm với các tham số ϵ và MinPts
- Khó xử lý dữ liệu có mật độ biến đổi
- Chi phí tính toán $O(n^2)$ trong trường hợp xấu nhất (hoặc $O(n \log n)$ nếu dùng spatial indexing)

2.3 Xác định số cụm tối ưu

2.3.1 Phương pháp Elbow (Elbow Method)

Phương pháp Elbow dựa trên quan sát rằng:

- Khi K tăng, inertia (tổng bình phương khoảng cách) giảm
- Có một điểm "gãy khúc" (elbow) nơi giảm chậm lại

- Điểm này chỉ ra K tối ưu

Công thức inertia:

$$\text{Inertia} = \sum_{i=1}^n \|x_i - \mu_{c_i}\|^2 \quad (2.2)$$

2.3.2 Chỉ số Silhouette (Silhouette Score)

Silhouette Score [14] đo lường mức độ tương tự của một điểm với cụm của nó so với các cụm khác. Các độ đo khác như Davies-Bouldin Index [4] và Calinski-Harabasz Index [3] cũng được sử dụng để đánh giá chất lượng phân cụm [8].

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (2.3)$$

Trong đó:

- $a(i)$ = khoảng cách trung bình từ điểm i tới các điểm khác trong cùng cụm
- $b(i)$ = khoảng cách trung bình nhỏ nhất từ điểm i tới các điểm trong các cụm khác
- $s(i) \in [-1, 1]$: giá trị cao hơn tốt hơn

Silhouette Score trung bình từ 0.5 đến 1 chỉ ra phân cụm tốt.

2.4 Giảm chiều dữ liệu: Principal Component Analysis (PCA)

PCA [9] là một kỹ thuật giảm chiều dữ liệu tuyến tính. Nó tìm các thành phần chính (principal components) có phương sai cao nhất.

- **PC1:** Hướng có phương sai lớn nhất
- **PC2:** Hướng trực giao với PC1 có phương sai lớn thứ hai

Công thức phương sai được giải thích:

$$\text{Variance Explained} = \frac{\lambda_i}{\sum_{j=1}^m \lambda_j} \quad (2.4)$$

Trong đó λ_i là eigenvalue thứ i .

Ưu điểm:

- Giảm số chiều mà vẫn giữ lại phần lớn thông tin
- Giúp trực quan hóa dữ liệu cao chiều

- Giảm overfitting
- Tăng tốc độ tính toán

2.5 Phân cụm khách hàng trong ngành tài chính

Phân cụm khách hàng thẻ tín dụng [10, 5] là ứng dụng quan trọng để quản lý rủi ro [11] và tối ưu hóa chiến lược kinh doanh. Phân cụm khách hàng thẻ tín dụng giúp:

1. **Phát triển sản phẩm:** Tạo các sản phẩm phù hợp cho mỗi phân khúc
2. **Giá định:** Đề xuất giá hoặc lãi suất khác nhau dựa trên phân khúc
3. **Quản lý rủi ro:** Xác định nhóm rủi ro cao để kiểm soát tốt hơn
4. **Tiếp thị được cá nhân hóa:** Tối ưu hóa các chiến dịch tiếp thị cho từng phân khúc
5. **Tăng giữ chân:** Phát hiện khách hàng có nguy cơ rời bỏ cao và đề xuất các ưu đãi
6. **Phát hiện gian lận:** Xác định hành vi bất thường có thể là gian lận

2.6 Trình trạng công nghệ hiện tại

Các công cụ phân tích phổ biến trong phân cụm dữ liệu:

- **R:** Thư viện stats, tidyverse, cluster
- **Python:** scikit-learn [13], scipy, pandas, numpy
- **SAS, SPSS:** Công cụ phân tích thương mại
- **Tableau, Power BI:** Trực quan hóa và business intelligence
- **Apache Spark MLlib:** Xử lý dữ liệu phân tán quy mô lớn

Trong báo cáo này, Python được lựa chọn sử dụng [7] vì:

- Cộng đồng lớn và hỗ trợ tốt
- Thư viện mạnh mẽ cho khai phá dữ liệu (scikit-learn, pandas)
- Mã nguồn mở và miễn phí
- Dễ học và triển khai nhanh
- Tích hợp tốt với Jupyter Notebook cho phân tích tương tác

Chương 3

PHƯƠNG PHÁP

3.1 Quy trình phân tích tổng thể

Quy trình phân tích được thực hiện theo các bước sau:

1. Thu thập và chẩn đoán dữ liệu
2. Xử lý dữ liệu (làm sạch, chuẩn hóa)
3. Phân tích khám phá (EDA)
4. Giảm chiều dữ liệu (PCA)
5. Xác định K tối ưu (Elbow + Silhouette)
6. Phân cụm K-means
7. Xác thực kết quả (Hierarchical, DBSCAN)
8. Phân tích đặc trưng cụm
9. Phát hiện dị biệt (Outliers)
10. Đưa ra khuyến nghị

3.2 Dữ liệu sử dụng

3.2.1 Nguồn dữ liệu

Dữ liệu sử dụng là CC GENERAL.csv - bộ dữ liệu công khai về khách hàng thẻ tín dụng.

3.2.2 Mô tả dữ liệu

Bảng 3.1: Danh sách các biến trong bộ dữ liệu

Biến	Loại	Mô tả	Đơn vị
CUST_ID	Chuỗi	Mã khách hàng	ID
BALANCE	Số thực	Số dư trong tài khoản	USD
BALANCE_FREQUENCY	Số thực	Tần suất có số dư	%
PURCHASES	Số thực	Tổng giá trị mua hàng	USD
ONEOFF_PURCHASES	Số thực	Tổng tiền mua một lần	USD
INSTALLMENTS_PURCHASES	Số thực	Tổng tiền mua trả góp	USD
CASH_ADVANCE	Số thực	Tổng tiền rút tiền mặt (cash advance)	USD
PURCHASES_FREQUENCY	Số thực	Tần suất mua hàng	%
CASH_ADVANCE_FREQUENCY	Số thực	Tần suất rút tiền	%
CASH_ADVANCE_TRX	Số nguyên	Số lần rút tiền	Lần
PURCHASES_TRX	Số nguyên	Số lần mua hàng	Lần
CREDIT_LIMIT	Số thực	Giới hạn tín dụng	USD
PAYMENTS	Số thực	Tổng tiền thanh toán	USD
MINIMUM_PAYMENTS	Số thực	Thanh toán tối thiểu	USD
PRC_FULL_PAYMENT	Số thực	Tỷ lệ thanh toán toàn bộ	%
TENURE	Số nguyên	Số tháng làm khách hàng	Tháng

Kích thước dữ liệu:

- Số hàng ban đầu: 8,950 khách hàng (sau xử lý NaN)
- Số cột: 18 (17 biến + 1 ID)
- Nguồn: Kaggle - Credit Card Dataset for Clustering

3.3 Kỹ thuật xử lý dữ liệu

3.3.1 Kiểm tra giá trị thiếu (Missing Values)

Các giá trị thiếu được xác định và xử lý như sau:

- **MINIMUM_PAYMENTS:** Điền bằng median
- **CREDIT_LIMIT:** Điền bằng median
- Các biến khác: Không có giá trị thiếu

Công thức điền median:

$$x_i = \text{median}(x) \text{ nếu } x_i \text{ là missing} \quad (3.1)$$

3.3.2 Phép biến đổi logarit (Log Transformation)

Do dữ liệu tài chính thường lệch phải (right-skewed), áp dụng biến đổi logarit:

$$x'_i = \log(1 + x_i) \quad (3.2)$$

Cộng 1 để tránh $\log(0)$.

Lợi ích:

- Giảm độ lệch của phân phối
- Giúp các giá trị lớn và nhỏ có trọng lượng tương đương
- Cải thiện hiệu suất mô hình

3.3.3 Chuẩn hóa dữ liệu (Standardization)

Sử dụng StandardScaler để chuẩn hóa:

$$z = \frac{x - \mu}{\sigma} \quad (3.3)$$

Trong đó:

- μ = giá trị trung bình của biến
- σ = độ lệch chuẩn của biến

Lý do:

- K-means nhạy cảm với thang đo biến
- Chuẩn hóa không làm thay đổi hình dạng phân phối
- Đảm bảo các biến có cùng ảnh hưởng

3.4 Giảm chiều dữ liệu

3.4.1 Tại sao cần giảm chiều?

- Dữ liệu gốc có 17 chiều, khó trực quan hóa

- Giảm thời gian tính toán
- Giảm nhiễu và overfitting
- Giúp phát hiện cấu trúc ẩn

3.4.2 Áp dụng PCA

PCA được áp dụng để giảm chiều dữ liệu từ 17 chiều xuống 2 chiều:

- **Giảm chiều:** Giảm từ 17 biến xuống 2 thành phần chính ($PC1, PC2$)
- **Giữ lại thông tin:** 2 PC giữ lại khoảng 56.46% phương sai của dữ liệu gốc
- **Trực quan hóa:** Dễ dàng vẽ biểu đồ phân tán 2D
- **Phân cụm:** K-means được thực hiện trên không gian PCA 2 chiều này

Việc sử dụng PCA 2D cho cả trực quan hóa và clustering giúp:

- Giảm nhiễu từ các biến ít quan trọng
- Tăng tốc độ tính toán
- Giảm overfitting
- Dễ dàng diễn giải và trình bày kết quả

$$\text{Variance Explained by 2 PCs} = \frac{\lambda_1 + \lambda_2}{\sum_{i=1}^{17} \lambda_i} \quad (3.4)$$

3.5 Xác định số cụm tối ưu

3.5.1 Phương pháp Elbow

Tính inertia cho mỗi K từ 2 đến 10:

$$\text{Inertia}(K) = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2 \quad (3.5)$$

Điểm "gãy khúc" nơi tốc độ giảm chậm lại chỉ ra K tối ưu.

3.5.2 Chỉ số Silhouette

Tính Silhouette Score trung bình cho mỗi K:

$$\text{SilhouetteScore}(K) = \frac{1}{n} \sum_{i=1}^n s(i) \quad (3.6)$$

K tối ưu thường có Silhouette Score cao nhất.

3.6 Phân cụm K-means

3.6.1 Thuật toán K-means

Input: Dữ liệu $X = \{x_1, \dots, x_n\}$, số cụm K

Output: Nhãn cụm cho mỗi điểm

1. **Khởi tạo:** Chọn ngẫu nhiên K tâm cụm $\mu_1, \dots, \mu_K$
 2. **Lặp:**
 - (a) **Gán:** Gán mỗi x_i tới cụm gần nhất: $c_i = \arg \min_k \|x_i - \mu_k\|$
 - (b) **Cập nhật:** $\mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$
 3. **Dừng:** Khi tâm cụm hội tụ hoặc số lần lặp đạt giới hạn
-

3.6.2 Khởi tạo K-means

Sử dụng k-means++ để khởi tạo tâm cụm:

- Chọn tâm đầu tiên ngẫu nhiên
- Mỗi tâm tiếp theo: chọn điểm xa tâm gần nhất
- Giảm nguy cơ hội tụ cục bộ không tốt

3.7 Xác thực kết quả phân cụm

3.7.1 So sánh với phân cụm phân cấp

Áp dụng phân cụm phân cấp với Ward linkage để xác nhận kết quả K-means.

3.7.2 Phát hiện dị biệt bằng DBSCAN

Sử dụng DBSCAN với tham số:

- $\epsilon = 0.5$ (bán kính láng giềng)
- `min_samples = 10` (số điểm tối thiểu)

Mục đích:

- Phát hiện điểm bất thường tự động
- Không cần xác định K trước
- Xác định khách hàng có hành vi khác biệt đáng kể

3.8 Phân tích và đặc trưng cụm

Đối với mỗi cụm, tính toán:

- **Thống kê mô tả** (mean, std, min, max) cho mỗi biến
- **Kích thước cụm** = số khách hàng trong cụm
- **Đặc trưng chính** = biến phân biệt nhất cụm này với cụm khác
- **Tên/Label** cho mỗi cụm dựa trên hành vi

3.9 Công cụ và môi trường

Ngôn ngữ lập trình: Python 3.8+

Thư viện chủ yếu:

- **pandas**: Xử lý dữ liệu bảng
- **numpy**: Tính toán số học
- **scikit-learn**: Thuật toán ML (KMeans, PCA, DBSCAN)
- **scipy**: Tính toán thống kê (linkage, dendrogram)
- **matplotlib, seaborn**: Trực quan hóa dữ liệu

Môi trường thực thi:

- Jupyter Notebook
- Python Virtual Environment (.venv)
- CPU đa lõi (xử lý song song)

Chương 4

XỬ LÝ DỮ LIỆU

4.1 Tổng quan bước xử lý dữ liệu

Xử lý dữ liệu là một bước cực kỳ quan trọng chiếm khoảng 70-80% thời gian dự án phân tích. Bước này bao gồm:

- Kiểm tra chất lượng dữ liệu
- Xử lý giá trị thiếu
- Xử lý giá trị ngoại lệ (outliers)
- Biến đổi dữ liệu
- Chuẩn hóa dữ liệu
- Kiểm tra và loại bỏ trùng lặp

4.2 Chẩn đoán chất lượng dữ liệu ban đầu

4.2.1 Kích thước và loại dữ liệu

Bảng 4.1: Thống kê cơ bản của dữ liệu gốc

Thông tin	Kích thước	Loại	Ghi chú
Số dòng	8,950	-	Khách hàng
Số cột	17	-	Biến đặc trưng
Bộ nhớ	0.86 MB	-	CSV dạng văn bản
Kiểu dữ liệu	17 (Num)	float64, int64	Toàn là số

4.2.2 Phát hiện giá trị thiếu

Kiểm tra từng biến:

Bảng 4.2: Giá trị thiếu trong mỗi biến

Biến	Giá trị thiếu	Tỷ lệ (%)
BALANCE	0	0.00
PURCHASES	0	0.00
CASH_ADVANCE	0	0.00
CREDIT_LIMIT	1	0.01
MINIMUM_PAYMENTS	313	3.50
Các biến khác	0	0.00

Quan sát:

- MINIMUM_PAYMENTS thiếu 313 giá trị (3.50%)
- CREDIT_LIMIT thiếu 1 giá trị (0.01%)
- Các biến khác hoàn chỉnh

4.3 Xử lý giá trị thiếu

4.3.1 Chiến lược điền (Imputation)

Do tỷ lệ giá trị thiếu nhỏ (<5%), sử dụng phương pháp điền median:

$$x_i^{\text{imputed}} = \begin{cases} \text{median}(x) & \text{nếu } x_i \text{ là missing} \\ x_i & \text{nếu } x_i \text{ có giá trị} \end{cases} \quad (4.1)$$

4.3.2 So sánh các phương pháp

Bảng 4.3: So sánh các phương pháp điền giá trị thiếu

Phương pháp	Ưu điểm	Nhược điểm	Khi nào dùng
Xóa hàng	Đơn giản	Mất dữ liệu	Rất ít thiếu
Mean/Median	Nhanh	Giảm phương sai	Thiếu ngẫu nhiên
Forward fill	Giữ xu hướng	Chỉ cho chuỗi thời gian	Chuỗi thời gian
KNN	Tính tương tự	Chậm	Dữ liệu nhỏ

4.3.3 Kết quả sau khi điền

Sau khi áp dụng điền median:

- MINIMUM_PAYMENTS median = \$312.34
- CREDIT_LIMIT median = \$3,000
- Tất cả giá trị thiếu được xử lý
- Dữ liệu hoàn chỉnh $8,950 \times 17$

4.4 Loại bỏ và xử lý dữ liệu không cần thiết

4.4.1 Xóa CUST_ID

CUST_ID là mã định danh khách hàng, không mang thông tin thống kê, vì vậy loại bỏ:

- Không cần thiết để phân cụm
- Giảm kích thước dữ liệu
- Lưu giữ nhưng không đưa vào ma trận đặc trưng X

4.5 Phép biến đổi dữ liệu

4.5.1 Tại sao cần biến đổi logarit

Biến đổi logarit là kỹ thuật phổ biến để xử lý dữ liệu lệch. Phân tích phân phối ban đầu cho thấy:

- BALANCE: Phân phối lệch phải mạnh
- PURCHASES: Phân phối lệch phải
- CASH_ADVANCE: Phân phối lệch phải

Biến đổi logarit giúp:

- Chuẩn hóa hình dạng phân phối
- Giảm ảnh hưởng của giá trị ngoại lệ
- Cải thiện hiệu suất mô hình tuyến tính

4.5.2 Áp dụng log transformation

$$X_{\log} = \log(1 + X) \quad (4.2)$$

Cộng 1 để tránh $\ln(0) = -\infty$ khi một khách hàng có số dư = 0.

Kết quả:

- Giảm độ lệch phải
- Tăng tính bình thường của phân phối
- Cải thiện hiệu suất clustering

4.6 Chuẩn hóa dữ liệu

4.6.1 Vấn đề thang đo (Scaling Problem)

Dữ liệu gốc có thang đo khác nhau:

- BALANCE: 0 – \$100,000+
- PURCHASES_FREQUENCY: 0 – 1.0 (tỷ lệ)
- Khoảng cách Euclid sẽ bị ưu tiên bởi biến lớn

4.6.2 StandardScaler

Áp dụng chuẩn hóa z-score:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \quad (4.3)$$

Kết quả:

- Tất cả biến có mean = 0, std = 1
- Phạm vi giá trị: khoảng $[-3, 3]$ cho hầu hết dữ liệu
- Không mất thông tin, chỉ thay đổi thang đo

4.6.3 Nguyên tắc Fit và Transform

Lưu ý: Đối với dự án phân cụm này, scaler được fit và transform trên toàn bộ dữ liệu (unsupervised learning). Tuy nhiên, trong các bài toán học có giám sát (supervised learning), nguyên tắc quan trọng là:

1. Chỉ fit scaler trên tập huấn luyện (training set)
2. Chỉ transform trên tập kiểm tra (test set)
3. KHÔNG fit lại trên tập kiểm tra

Ví dụ minh họa cho supervised learning:

$$\text{scaler.fit}(X_{\text{train}}) \Rightarrow z_{\text{train}} = \text{scaler.transform}(X_{\text{train}}) \Rightarrow z_{\text{test}} = \text{scaler.transform}(X_{\text{test}}) \quad (4.4)$$

Trong dự án này: Do không có chia tập train/test, sử dụng `fit_transform(X)` trên toàn bộ dữ liệu.

4.7 Thống kê mô tả sau xử lý

Bảng 4.4: Thống kê mô tả sau xử lý log transformation

Biến	Mean	Std	Min	Max	Q50
BALANCE	6.16	2.01	0.00	9.85	6.77
PURCHASES	4.90	2.92	0.00	10.80	5.89
CASH_ADVANCE	3.32	3.57	0.00	10.76	0.00
(Các biến khác tương tự)					

Lưu ý: Sau bước log transformation, dữ liệu được chuẩn hóa bằng StandardScaler để tất cả biến có mean = 0 và std = 1, chuẩn bị cho thuật toán phân cụm.

4.8 Kiểm tra trùng lặp

Kiểm tra xem có hàng trùng lặp hoàn toàn:

- Số hàng trùng lặp: 0
- Dữ liệu hoàn toàn duy nhất

4.9 Tạm kết luận về xử lý dữ liệu

Sau khi hoàn tất bước xử lý:

- Không còn giá trị thiếu
- Dữ liệu đã được biến đổi logarit
- Dữ liệu đã được chuẩn hóa
- Không có hàng trùng lặp
- Sẵn sàng cho bước phân tích tiếp theo

Ma trận dữ liệu cuối cùng: $X \in \mathbb{R}^{8950 \times 17}$, kích thước phù hợp cho phân cụm.

Chương 5

PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

5.1 Mục tiêu EDA

Chương này tập trung phân tích thống kê mô tả và quan hệ giữa các biến tài chính để:

- Hiểu đặc điểm phân bố dữ liệu trước khi phân cụm
- Xác định biến có độ phân biệt cao giữa các nhóm khách hàng
- Kiểm tra điều kiện phù hợp cho K-means

5.2 Thống kê mô tả các biến chính

Bảng 5.1: Thống kê mô tả cho các biến tài chính trọng yếu (N = 8,950)

Biến	Trung bình	Độ lệch chuẩn	Trung vị	Giá trị lớn nhất
BALANCE	\$1,564	\$2,095	\$873	\$19,043
PURCHASES	\$1,003	\$2,136	\$361	\$49,040
CASH_ADVANCE	\$979	\$2,097	\$0	\$47,137
CREDIT_LIMIT	\$4,494	\$3,639	\$3,000	\$30,000
PAYMENTS	\$1,733	\$2,895	\$857	\$50,721
MINIMUM_PAYMENTS	\$864	\$2,372	\$312	\$76,406
PRC_FULL_PAYMENT	15.37%	29.3%	0.00%	100%
TENURE	11.5 tháng	1.3 tháng	12 tháng	12 tháng

Nhận xét chính:

- Dữ liệu có phân phối lệch phải rõ ở các biến tiền tệ (BALANCE, PURCHASES, CASH_ADVANCE)

- Trung vị thấp hơn nhiều so với trung bình ở nhiều biến, cho thấy tồn tại nhóm khách hàng chi tiêu/rút tiền rất cao
- TENURE tập trung trong khoảng 6-12 tháng, phù hợp đặc trưng dữ liệu tổng hợp theo chu kỳ năm

5.3 Phân tích hành vi tài chính tổng quan

5.3.1 Hành vi chi tiêu và thanh toán

- PURCHASES trung bình \$1,003/tháng, nhưng phân tán lớn, phản ánh khác biệt mạnh về mức độ sử dụng thẻ
- PAYMENTS trung bình \$1,733 cao hơn PURCHASES trung bình, cho thấy tồn tại nhóm khách hàng thanh toán tích cực
- PRC_FULL_PAYMENT trung bình 15.37%: phần lớn khách hàng không thanh toán toàn bộ dư nợ mỗi kỳ

5.3.2 Hành vi rút tiền mặt

- CASH_ADVANCE trung bình \$979, trung vị bằng 0: đa số khách không rút tiền thường xuyên
- Nhóm nhỏ khách hàng rút tiền rất cao kéo trung bình tăng mạnh, là tín hiệu rủi ro tín dụng cần theo dõi

5.4 Tương quan giữa các biến

Bảng 5.2: Một số cặp tương quan đáng chú ý

Biến 1	Biến 2	Hệ số tương quan
PAYMENTS	MINIMUM_PAYMENTS	0.89
PURCHASES	PURCHASES_TRX	0.74
BALANCE	CREDIT_LIMIT	0.53
CASH_ADVANCE	CASH_ADVANCE_TRX	0.69

Diễn giải:

- PAYMENTS và MINIMUM_PAYMENTS tương quan rất cao, phản ánh quan hệ trực tiếp trong hành vi trả nợ
- PURCHASES và PURCHASES_TRX tương quan cao, phù hợp trực giác: số lần mua tăng kéo tổng chi tiêu tăng
- Không có tương quan tuyệt đối gần 1.0 giữa các biến chính, nên thông tin giữa các biến vẫn đủ đa dạng để phân cụm

5.5 Kiểm tra điều kiện cho phân cụm

- Dữ liệu đã được xử lý thiếu và chuẩn hóa ở Chương 4
- Các biến có phương sai khác 0, không có biến hằng
- Cỡ mẫu 8,950 đủ lớn cho phân cụm ổn định
- Có sự khác biệt hành vi rõ giữa nhóm chi tiêu cao, rút tiền cao và nhóm sử dụng thấp

5.6 Kết luận chương

Kết quả EDA cho thấy dữ liệu có đủ độ biến thiên và cấu trúc hành vi để thực hiện phân cụm khách hàng. Hai chiều hành vi nổi bật nhất là:

1. Mức độ chi tiêu và thanh toán
2. Mức độ phụ thuộc vào rút tiền mặt

Các phát hiện này là cơ sở trực tiếp cho bước giảm chiều và phân cụm ở Chương 6.

Chương 6

KỸ THUẬT VÀ KẾT QUẢ PHÂN CỤM

6.1 Giảm chiều dữ liệu bằng PCA

6.1.1 Thiết lập PCA

Dữ liệu sau chuẩn hóa được giảm từ 17 chiều xuống 2 thành phần chính để trực quan hóa và huấn luyện phân cụm:

$$X_{n \times 17} \rightarrow X_{n \times 2} \quad (6.1)$$


Bảng 6.1: Tỷ lệ phương sai được giữ lại bởi PCA

Thành phần	Variance Ratio	Cộng dồn
PC1	34.5%	34.5%
PC2	22.0%	56.46%

Nhận xét:

- Hai thành phần đầu giữ lại 56.46% phương sai, đủ để phản ánh cấu trúc hành vi chính
- PC1 chủ yếu liên quan đến cường độ sử dụng tín dụng (BALANCE, PURCHASES)
- PC2 phản ánh xu hướng rút tiền mặt và tần suất giao dịch

6.2 Xác định số cụm tối ưu



Hình 6.1: Elbow và Silhouette theo số cụm

Kết luận lựa chọn K:

- Elbow Method cho điểm gãy rõ tại $K = 4$
- Silhouette tại $K = 4$ đạt 0.215 (mức tách cụm vừa phải)
- $K=4$ được chọn vì cân bằng giữa chất lượng thống kê và khả năng hành động trong kinh doanh

6.3 K-means với K=4

6.3.1 Thiết lập mô hình

- Thuật toán: K-means++
- Số cụm: 4
- `n_init`: 10
- `max_iter`: 300
- Số vòng lặp hội tụ: 19

6.3.2 Đánh giá mô hình

Bảng 6.2: Các độ đo đánh giá tại K=4

Độ đo	Giá trị
Silhouette Score	0.215
Davies-Bouldin Index	1.64
Calinski-Harabasz Index	2,335
Inertia	85,335

6.3.3 Kiểm định độ ổn định của kết quả K-means

Để tăng độ tin cậy học thuật, mô hình được chạy lặp lại 30 lần với các giá trị `random_state` khác nhau (0–29), giữ nguyên toàn bộ pipeline tiền xử lý (median imputation, `log1p`, `StandardScaler`) và siêu tham số K-means ($K=4$, $n_init=10$, $max_iter=300$).

Bảng 6.3: Độ ổn định của các chỉ số qua 30 lần chạy

Chỉ số	Trung bình	Độ lệch chuẩn	Khoảng giá trị
Silhouette	0.2154	0.0006	[0.2150; 0.2187]
Davies-Bouldin	1.6419	0.0029	[1.6364; 1.6551]
Calinski-Harabasz	2334.52	1.50	[2326.59; 2334.82]
Inertia	85339.96	24.09	[85209.59; 85346.56]
Số vòng lặp hội tụ	19.50	–	[11; 34]
ARI cặp đôi giữa các lần chạy	0.9695	0.0827	[0.6581; 1.0000]

Diễn giải:

- Biến thiên của Silhouette, DBI, CHI và Inertia rất nhỏ, cho thấy chất lượng phân cụm ổn định theo khởi tạo ngẫu nhiên.
- ARI trung bình cao (0.9695) cho thấy cấu trúc phân cụm nhất quán ở đa số lần chạy.
- Một số cặp lần chạy có ARI thấp hơn ($\min = 0.6581$), phản ánh có mức dao động cục bộ do dữ liệu có vùng chồng chéo giữa các cụm.

6.3.4 Quy mô các cụm

Bảng 6.4: Phân bố khách hàng theo cụm K-means

Cụm	Số lượng	Tỷ lệ	Đặc trưng nổi bật
0	1,504	16.8%	BALANCE cao, CASH_ADVANCE rất cao, thanh toán đầy đủ thấp
1	2,206	24.6%	PURCHASES cao nhất, thanh toán tốt, CASH_ADVANCE rất thấp
2	2,758	30.8%	Mức sử dụng thấp trên hầu hết biến, tiềm năng kích hoạt
3	2,482	27.7%	Phụ thuộc rút tiền mặt, PURCHASES rất thấp, rủi ro tín dụng cao
Tổng	8,950	100%	-

6.4 Phân tích chi tiết 4 cụm

6.4.1 Cụm 0: Khách hàng rủi ro cao

- BALANCE: \$3,187 (cao hơn trung bình 103.7%)
- CASH_ADVANCE: \$2,551 (cao hơn trung bình 160.6%)
- PRC_FULL_PAYMENT: 3.66% (rất thấp)

Diễn giải: Nhóm này có xu hướng sử dụng hạn mức để rút tiền mặt và trả nợ không đầy đủ, cần ưu tiên quản trị rủi ro.

6.4.2 Cụm 1: Khách hàng VIP (Premium/VIP Customers)

- PURCHASES: \$2,579 (cao nhất)
- PAYMENTS: \$2,492 (cao)
- CASH_ADVANCE: \$40 (rất thấp)
- PRC_FULL_PAYMENT: 23.80% (cao)

Diễn giải: Đây là nhóm giá trị cao, hành vi sử dụng thẻ lành mạnh, phù hợp chiến lược giữ chân và bán chéo.

6.4.3 Cụm 2: Khách hàng ít sử dụng

- BALANCE: \$249
- PURCHASES: \$443
- CASH_ADVANCE: \$24
- PRC_FULL_PAYMENT: 25.74%

Diễn giải: Nhóm quy mô lớn nhất nhưng mức sử dụng thấp; có thể tăng doanh thu nếu kích hoạt đúng cách.

6.4.4 Cụm 3: Khách hàng rút tiền mặt

- CASH_ADVANCE: \$1,921
- PURCHASES: \$30
- PRC_FULL_PAYMENT: 3.46%

Diễn giải: Nhóm có rủi ro tín dụng cao do phụ thuộc rút tiền mặt và khả năng trả nợ thấp.

6.5 Đối chiếu DBSCAN

Sử dụng DBSCAN với $\text{eps}=0.5$ và $\text{min_samples}=10$:

- Số cụm tìm thấy: 9
- Số điểm dị biệt: 8,486 (94.82%)

Kết luận đối chiếu: Với bộ tham số này, DBSCAN không phù hợp cho bài toán phân khúc khách hàng trong dữ liệu hiện tại. K-means vẫn là lựa chọn chính cho báo cáo.

6.6 Kết luận chương

- K-means với $K=4$ tạo ra 4 nhóm khách hàng có ý nghĩa kinh doanh rõ ràng
- Các cụm thể hiện tốt hai trục hành vi chính: chi tiêu và phụ thuộc rút tiền mặt
- Kết quả là cơ sở trực tiếp cho chương khuyến nghị kinh doanh

Chương 7

THÔNG TIN CHI TIẾT KINH DOANH VÀ KHUYẾN NGHỊ

7.1 Phân tích chi tiết các phân khúc

7.1.1 Cụm 0: Khách hàng rủi ro cao (High-Risk Customers)

Hồ sơ cụm

Bảng 7.1: Hồ sơ chi tiết Cụm 0

Chỉ tiêu	Cụm 0	Toàn bộ	Chênh lệch
Kích thước	1,504	8,950	16.8%
BALANCE trung bình	\$3,187	\$1,564	+103.7%
CASH_ADVANCE trung bình	\$2,551	\$979	+160.6%
CREDIT_LIMIT trung bình	\$5,607	\$4,494	+24.7%
PAYMENTS trung bình	\$2,769	\$1,733	+59.8%
PURCHASES trung bình	\$1,326	\$1,003	+32.2%
PRC_FULL_PAYMENT	3.66%	15.37%	-76.2%

Hành vi mua hàng

- **Đặc điểm:** Rút tiền mặt nhiều (\$2,551), nhưng tỷ lệ thanh toán đầy đủ rất thấp (3.66%)
- **CASH_ADVANCE/CREDIT_LIMIT:** 64.3% hạn mức dùng để rút tiền
- **Rủi ro:** Nhóm này có tỷ lệ mặc định dự kiến cao (5-8%)

Chiến lược hạn chế rủi ro

1. **Giám sát:** Gắn cờ các giao dịch rút tiền > \$1,500
2. **Hạn chế rút tiền:** Giảm giới hạn rút tiền xuống 20-30% hạn mức tín dụng
3. **Tăng lãi suất:** Tăng lãi suất rút tiền mặt lên 3-5%
4. **Telesales:** Liên hệ tích cực khuyến khích thanh toán toàn bộ
5. **Phát hiện gian lận:** Sử dụng ML phát hiện các giao dịch bất thường

7.1.2 Cụm 1: Khách hàng VIP (Premium/VIP Customers)**Đặc điểm nổi bật**

Bảng 7.2: Đặc điểm Cụm 1 (VIP)

Chỉ tiêu	Cụm 1	Toàn bộ	Chênh lệch
Kích thước	2,206 (24.6%)	8,950	-10.9%
PURCHASES trung bình	\$2,579	\$1,003	+157.1%
PAYMENTS trung bình	\$2,492	\$1,733	+43.8%
CASH_ADVANCE trung bình	\$40	\$979	-95.9%
CREDIT_LIMIT trung bình	\$5,938	\$4,494	+32.1%
PRC_FULL_PAYMENT	23.80%	15.37%	+54.9%

Hành vi và giá trị

- **Hành vi mua hàng:** Mua hàng rất cao (\$2,579/tháng), hầu như không rút tiền (\$40/tháng)
- **Thanh toán:** Tỷ lệ thanh toán đầy đủ cao (23.80%), thanh toán trung bình \$2,492/tháng
- **Giá trị khách hàng:** Nhóm VIP cao giá trị nhất, có khả năng mặc định thấp
- **Lợi nhuận:** Mỗi khách hàng tài trợ \$248/tháng từ lãi suất + phí dịch vụ

Chiến lược giữ chân VIP

1. **Chương trình VIP cao cấp:** Tích điểm gấp đôi, hoàn tiền 2-3% cho mọi giao dịch mua hàng
2. **Quyền lợi đặc biệt:** Mở thẻ Platinum, dịch vụ concierge 24/7, bảo hiểm du lịch mở rộng
3. **Ưu đãi mua sắm:** Hợp tác với trung tâm thương mại và nhà hàng cao cấp, ưu đãi 5-10%

4. **Tương tác cá nhân:** Bố trí chuyên viên quản lý quan hệ riêng, liên lạc định kỳ
5. **Tăng hạn mức:** Tự động tăng hạn mức khi thanh toán đầy đủ liên tục
6. **Lãi suất ưu đãi:** Giữ lãi suất dưới mức trung bình (12-14%/năm)

Dự báo giá trị

- **Tỷ suất lợi nhuận hàng tháng:** \$248 (lãi suất + phí dịch vụ)
- **Thời gian giữ chân trung bình:** 36 tháng (3 năm) - cao nhất
- **CLV ước tính:** $\$248 \times 36 \text{ tháng} = \$8,928$ mỗi khách
- **Tổng giá trị cụm:** $\$8,928 \times 2,206 = \19.7M - cao nhất trong tất cả cụm

7.1.3 Cụm 2: Khách hàng ít sử dụng (Low-Activity Customers)

Hồ sơ cụm

Bảng 7.3: Hồ sơ chi tiết Cụm 2

Chỉ tiêu	Cụm 2	Toàn bộ	Chênh lệch
Kích thước	2,758 (30.8%)	8,950	+6.1%
BALANCE trung bình	\$249	\$1,564	-84.1%
PURCHASES trung bình	\$443	\$1,003	-55.9%
CASH_ADVANCE trung bình	\$24	\$979	-97.5%
CREDIT_LIMIT trung bình	\$3,182	\$4,494	-29.2%
PAYMENTS trung bình	\$674	\$1,733	-61.1%
PRC_FULL_PAYMENT	25.74%	15.37%	+67.5%

Tại sao sử dụng tối thiểu?

- **Khách hàng cơ bản:** Có thẻ nhưng ít sử dụng (BALANCE chỉ \$249)
- **Tỷ lệ thanh toán cao:** 25.74% thanh toán đầy đủ - cao hơn trung bình
- **Hạn chế tín dụng:** CREDIT_LIMIT thấp (\$3,182), rủi ro tín dụng tương đối thấp
- **Nhu cầu thấp:** Có thể do thu nhập thấp, hoặc sử dụng phương tiện thanh toán khác

Cơ hội phát triển

1. **Chiến dịch kích hoạt:** Gửi ưu đãi hoàn tiền 3-5% cho giao dịch đầu tiên
2. **Ngưỡng tham gia thấp:** Cung cấp các gói dịch vụ với phí thấp hoặc miễn phí
3. **Giáo dục tài chính:** SMS/Email về lợi ích của việc sử dụng thẻ
4. **Hợp tác đối tác:** Liên kết với cửa hàng, nhà hàng để tăng mức ưu đãi
5. **Lộ trình nâng hạng:** Khi khách hàng tăng sử dụng, nâng cấp sang thẻ hạng cao hơn
6. **Khoản vay nhỏ:** Cung cấp khoản vay quy mô nhỏ cho khách có nhu cầu

ROI của chiến dịch

- **Chi phí thu hút:** \$5-10 mỗi khách
- **Tỷ lệ chuyển đổi dự tính:** 15-20% (415-550 khách từ 2,758)
- **Tổng chi phí:** $2,758 \times \$7 = \$19.3K$
- **Tiềm năng lợi nhuận tăng:** $500 \times \$80/\text{năm} \times 3 \text{ năm} = \$120K$
- **ROI:** 520% trong 3 năm

7.1.4 Cụm 3: Khách hàng rút tiền mặt (Cash Advance Users)**Đặc trưng chính**

Bảng 7.4: Hồ sơ Cụm 3 (Cash Advance Users)

Chỉ tiêu	Cụm 3	Toàn bộ	Chênh lệch
Kích thước	2,482 (27.7%)	8,950	+9.9%
CASH_ADVANCE trung bình	\$1,921	\$979	+96.3%
BALANCE trung bình	\$2,142	\$1,564	+36.9%
PURCHASES trung bình	\$30	\$1,003	-97.0%
CREDIT_LIMIT trung bình	\$3,996	\$4,494	-11.1%
PAYMENTS trung bình	\$1,608	\$1,733	-7.2%
PRC_FULL_PAYMENT	3.46%	15.37%	-77.5%

Hành vi và rủi ro

- **Hành vi chính:** Rút tiền mặt rất cao (\$1,921/tháng), hầu như không mua hàng (\$30/tháng)

- **Rủi ro nợ:** Rất cao - chỉ 3.46% thanh toán đầy đủ
- **Tỷ lệ mặc định dự kiến:** 5-8% (so với trung bình 2%)
- **Phạm vi rủi ro tiềm ẩn:** $\$1,921 \times 2,482$ khách = $\$4.77M$ nợ rút tiền mặt

Chiến lược hạn chế rủi ro

1. **Giám sát chặt chẽ:** Gắn cờ các giao dịch rút tiền > \$1,000 là đáng ngờ
2. **Hạn chế rút tiền:** Giảm giới hạn rút tiền xuống 15-20% hạn mức tín dụng
3. **Lãi suất cao:** Tăng lãi suất rút tiền mặt lên 4-6% (tùy mục tiêu rủi ro)
4. **Khuyến khích thanh toán:** Telesales liên hệ tích cực, gửi thông báo nợ
5. **Phát hiện gian lận:** Sử dụng mô hình máy học để phát hiện giao dịch bất thường
6. **Tư vấn tài chính:** Gửi tài liệu về quản lý nợ và lập kế hoạch chi tiêu

Dự báo giá trị

- **Tỷ suất lợi nhuận hàng tháng:** \$87 (lãi suất cao do rủi ro)
- **Thời gian giữ chân trung bình:** 18 tháng (rủi ro cao, có thể mặc định)
- **CLV ước tính:** $\$87 \times 18$ tháng = \$1,566 mỗi khách
- **Tổng giá trị cụm:** $\$1,566 \times 2,482$ = \$3.9M
- **Chất lượng tín dụng:** Giám sát chặt chẽ, sẵn sàng thu nợ gấp nếu cần

7.2 Phân tích DBSCAN (Phân tích giá trị cực trị)

7.2.1 Kết quả DBSCAN

Thuật toán phân cụm DBSCAN (với $\text{eps}=0.5$, $\text{min_samples}=10$) đã xác định các điểm dị biệt:

Bảng 7.5: Kết quả phân cụm DBSCAN

Loại dữ liệu	Số lượng
Số cụm được tìm thấy	9
Số điểm dị biệt (outlier)	8,486
Tỷ lệ điểm dị biệt	94.82%
Số điểm thuộc cụm	464

7.2.2 Giải thích và nhận xét

Kết quả DBSCAN cho thấy rằng với các tham số $\text{eps}=0.5$ và $\text{min_samples}=10$, thuật toán xác định 94.82% dữ liệu là điểm dị biệt. Điều này chỉ ra rằng:

- **DBSCAN không phù hợp:** Các điểm dữ liệu trong không gian PCA 2 chiều không tập trung thành cụm mật độ cao như kỳ vọng
- **Phân bố dữ liệu:** Khách hàng phân tán khắp không gian PCA, không có khoảng không gian rõ ràng giữa các nhóm
- **K-means phù hợp hơn:** K-means ($k=4$) với chỉ số Silhouette 0.215 là lựa chọn phù hợp hơn DBSCAN cho dữ liệu này

7.2.3 Giá trị cực trị

Để phát hiện những khách hàng có giá trị cực trị (extreme outliers) cần chú ý, báo cáo xác định các điểm dữ liệu có giá trị PCA ở vùng biên:

- **$\text{PC1} > 3$ hoặc $\text{PC1} < -3$:** Khách hàng có mẫu hành vi sử dụng rất khác biệt
- **$\text{PC2} > 3$ hoặc $\text{PC2} < -3$:** Khách hàng với mô hình chi tiêu / rút tiền rất khác
- **Hành động:** Kiểm tra thủ công các khách hàng này để phát hiện gian lận hoặc cơ hội bán chéo đặc biệt

7.3 Khuyến nghị hành động

7.3.1 Ngắn hạn (0-3 tháng)

1. **Phân loại 4 cụm:** Cập nhật CRM với nhãn K-means (Cụm 0-3), dùng cho nhắm mục tiêu tiếp thị
2. **Chiến dịch cho Cụm 0 (rủi ro cao):** Giám sát giao dịch, ngăn cản rút tiền $> \$1,500$
3. **Chiến dịch giữ chân Cụm 1 (VIP):** Cung cấp quyền lợi đặc biệt, tăng hạn mức tín dụng có kiểm soát
4. **Chiến dịch kích hoạt Cụm 2 (ít sử dụng):** Gửi mã khuyến mãi \$25 hoàn tiền cho giao dịch từ \$100
5. **Quản trị rủi ro Cụm 3 (rút tiền mặt):** Hạn chế rút tiền, điều chỉnh lãi suất, liên hệ nhắc nợ

6. **Rà soát điểm cực trị:** Kiểm tra các khách hàng có $PC1/PC2 > 3$ hoặc < -3 để phát hiện gian lận

7.3.2 Trung hạn (3-6 tháng)

1. **Sản phẩm theo phân khúc:** Thiết kế gói sản phẩm riêng cho từng cụm (bảo hiểm cho Cụm 0, hoàn tiền cao cho Cụm 1, miễn phí kích hoạt cho Cụm 2)
2. **Chương trình bán chéo:** Bảo hiểm du lịch cho Cụm 1, khoản vay nhỏ cho Cụm 2
3. **Tối ưu CLV:** Phân tích mẫu chi tiêu, tối ưu tần suất và kênh tương tác
4. **Dự báo rời bỏ:** Xây dựng mô hình dự báo churn cho từng cụm
5. **Định giá linh hoạt:** Điều chỉnh lãi suất rút tiền theo từng cụm khách hàng

7.3.3 Dài hạn (6-12 tháng)

1. **Mô hình phân khúc trong vận hành:** Áp dụng K-means trong hệ thống thời gian thực để phân loại khách hàng mới
2. **Cá nhân hóa tự động:** Tự động gửi ưu đãi phù hợp bằng cách kết hợp phân cụm và dự báo hành vi
3. **Phát hiện gian lận:** Xây dựng mô hình phát hiện gian lận dựa trên giá trị cực trị kết hợp máy học
4. **Tác động doanh thu:** Dự tính tăng doanh thu 5-10% nhờ chiến lược tối ưu theo cụm
5. **Cải thiện giữ chân:** Giảm tỷ lệ churn 2-3 điểm phần trăm nhờ tương tác chủ động

7.4 KPI theo dõi

Bảng 7.6: KPI theo dõi hiệu quả phân cụm K-means

Cụm	KPI chính	Mục tiêu
Cụm 0 (High-Risk) - -	Tỷ lệ vỡ nợ Tỷ lệ thanh toán đầy đủ Tỷ lệ duy trì	< 5% (giảm từ mức dự kiến 5-8%) > 10% (tăng từ 3.66%) > 85% (nhóm rủi ro cần theo dõi)
Cụm 1 (VIP) - -	Tỷ lệ rời bỏ (churn) Tỷ lệ chuyển đổi bán chéo Giá trị giao dịch trung bình	< 2% (duy trì nhóm giá trị cao) > 40% Duy trì > \$2,500/tháng
Cụm 2 (Low-Activity) - -	Tỷ lệ kích hoạt Tăng trưởng chi tiêu trung bình Tỷ lệ chuyển dịch sang Cụm 1	> 30% +50% (mục tiêu 2 năm) > 10%
Cụm 3 (Cash Advance Users) - -	Tỷ lệ vỡ nợ Mức tăng tỷ lệ thanh toán đầy đủ Mức sử dụng rút tiền mặt	< 8% > 5% (tăng từ 3.46%) Giảm 20-30%

Chương 8

KẾT LUẬN

8.1 Tóm tắt các kết quả chính

Báo cáo này đã trình bày một phân tích toàn diện về phân cụm khách hàng thẻ tín dụng bằng các kỹ thuật khai phá dữ liệu. Các kết quả chính bao gồm:

8.1.1 Về dữ liệu

- Dữ liệu từ 8,950 khách hàng và 17 biến tài chính
- Sau xử lý, dữ liệu hoàn chỉnh và sạch, sẵn sàng cho phân tích
- Các biến có phân phối lệch phải điển hình của dữ liệu tài chính
- Có mối tương quan vừa phải giữa các biến

8.1.2 Về phương pháp

- Áp dụng K-means clustering với PCA giảm chiều
- Sử dụng Elbow Method và Silhouette Score để xác định K=4 tối ưu
- Xác thực kết quả bằng Hierarchical Clustering và DBSCAN
- K-means cho hiệu suất tốt hơn với Silhouette Score = 0.215

8.1.3 Về kết quả phân cụm

Tìm được 4 phân khúc khách hàng rõ ràng:

Bảng 8.1: Tóm tắt 4 cụm

Cụm	Tỷ lệ	Tên	Giá trị
Cụm 0	16.8%	High-Risk Customers	Rủi ro
Cụm 1	24.6%	Premium/VIP Customers	Rất cao
Cụm 2	30.8%	Low-Activity	Tiềm năng
Cụm 3	27.7%	Cash Advance Users	Rủi ro

8.1.4 Về giá trị kinh doanh

- CLV ước tính cho các cụm cho thấy sự khác biệt giá trị rõ rệt giữa các phân khúc
- Cụm 1 (Premium/VIP) là nhóm có giá trị cao nhất với tổng giá trị \$19.7M
- Cụm 3 (Cash Advance Users) có rủi ro nợ tiềm ẩn khoảng \$4.77M trong rút tiền mặt
- Cụm 2 (Low-Activity) có tiềm năng phát triển: \$120K từ 1 campaign đơn giản

8.2 Các khám phá chính

8.2.1 Phân khúc có sự chồng chéo

Mặc dù có 4 cụm, nhưng:

- Silhouette Score = 0.215 ở mức thấp, cho thấy các cụm có sự chồng chéo
- Các cụm có ranh giới tương đối mờ trên bản đồ PCA
- DBSCAN xác định 8,486 khách (94.82%) là outliers, cho thấy thuật toán này không phù hợp

Giải thích: Hành vi khách hàng tài chính là phức tạp với nhiều mức độ khác nhau. K-means vẫn là lựa chọn phù hợp nhất cho dữ liệu này.

8.2.2 Cụm 1 (Premium/VIP) là nhóm giá trị cao nhất

- Chiếm 24.6% khách hàng
- Mua hàng cao nhất (\$2,579/tháng), thanh toán đầy đủ 23.80%
- Cần chiến lược giữ chân và phát triển VIP loyalty

8.2.3 Cụm 2 (Low-Activity) có tiềm năng phát triển cao

- Nhóm lớn nhất (30.8%), chưa kích hoạt sử dụng (BALANCE chỉ \$249)
- Tỷ lệ thanh toán đầy đủ cao (25.74%), cho thấy khả năng tài chính tốt
- ROI từ activation campaign rất cao (520%)

8.2.4 Cụm 3 (Cash Advance Users) là nhóm rủi ro cao

- Chiếm 27.7% khách hàng
- Rút tiền mặt rất cao (\$1,921/tháng) nhưng hầu như không mua hàng (\$30/tháng)
- Tỷ lệ thanh toán đầy đủ rất thấp (3.46%), cần giám sát chặt chẽ

8.3 Hạn chế của nghiên cứu

8.3.1 Về dữ liệu

- **Snapshot duy nhất:** Dữ liệu từ một thời điểm, không có chuỗi thời gian
- **Thiếu biến nhân khẩu học:** Không có thông tin về độ tuổi, giới tính, địa điểm
- **Không có nhãn:** Không có target variable như churn hoặc default để xác thực
- **Kích thước dữ liệu:** 8,950 khách hàng có thể không đủ lớn cho các ngân hàng lớn

8.3.2 Về phương pháp

- **K-means giả định:** Các cụm có hình dạng gần cầu, kích thước tương đương
- **Không giám sát:** Không có nhãn để xác thực kết quả
- **PCA giảm thông tin:** Giảm xuống 2D chỉ giữ 56.46% phương sai cho trực quan hóa
- **Tham số DBSCAN:** Chọn eps, min_samples một cách heuristic, không tối ưu
- **Độ nhạy khởi tạo:** K-means phụ thuộc tâm khởi tạo; mặc dù kiểm định 30 lần chạy cho thấy chỉ số ổn định, vẫn tồn tại dao động cục bộ ở vùng ranh giới cụm
- **Đánh đổi giữa diễn giải và độ tách cụm:** K=4 được chọn vì giá trị kinh doanh và khả năng diễn giải, không phải cấu hình có độ tách cụm tuyệt đối cao nhất

8.3.3 Về giá trị kinh doanh

- **CLV ước tính:** Dựa trên các giả định về lãi suất, giữ chân, không chắc chắn
- **Không tính đến chi phí:** Marketing cost, operational cost không được tính
- **Không có kiểm chứng A/B:** Các khuyến nghị chưa được kiểm tra thực tế

8.4 Hướng phát triển tương lai

8.4.1 Cải thiện dữ liệu

1. **Thêm dữ liệu thời gian:** Thu thập dữ liệu hàng tháng để xem xu hướng
2. **Thêm biến nhân khẩu học:** Độ tuổi, giới tính, địa vị xã hội, thu nhập
3. **Thêm biến hành vi:** Sở thích mua sắm, loại hình giao dịch
4. **Nhãn churn:** Thu thập data về khách hàng churn hoặc default để huấn luyện

8.4.2 Cải thiện phương pháp

1. **Stability selection có hệ thống:** Chuẩn hóa quy trình lặp nhiều seed theo chu kỳ, báo cáo $\text{mean} \pm \text{std}$ và khoảng tin cậy cho các chỉ số chính
2. **Đánh giá ngoài mẫu theo thời gian:** Huấn luyện trên giai đoạn trước, đánh giá phân cụm trên giai đoạn sau để kiểm tra độ bền theo biến động hành vi khách hàng
3. **Gaussian Mixture Model:** Tính xác suất thuộc cụm của mỗi khách, phù hợp dữ liệu có chồng chéo
4. **Fuzzy C-means:** Cho phép khách hàng nằm giữa các cụm với mức độ thành viên mềm
5. **Spectral Clustering:** Xử lý các cụm có hình dạng phức tạp hơn giả định cầu của K-means
6. **Deep Learning:** Autoencoder/VAE để học biểu diễn đặc trưng tốt hơn trước khi phân cụm
7. **Online learning:** Cập nhật phân cụm khi có khách hàng mới theo thời gian thực

8.4.3 Mở rộng ứng dụng

1. **Phân loại khách hàng mới:** Huấn luyện classifier để dự báo cụm của khách mới
2. **Churn prediction:** Dùng cụm + features để dự báo khách nào sẽ rời bỏ
3. **Fraud detection:** Dùng cụm + anomaly detection để phát hiện gian lận
4. **Recommendation system:** Gợi ý sản phẩm dựa trên hành vi cụm
5. **Dynamic pricing:** Điều chỉnh lãi suất, fee dựa trên cụm
6. **Product development:** Thiết kế sản phẩm mới cho các phân khúc

8.4.4 Cải thiện hiệu quả kinh doanh

1. **A/B Testing:** Kiểm chứng các khuyến nghị marketing bằng A/B test
2. **ROI Tracking:** Đo lường hiệu quả từng campaign cho mỗi cụm
3. **Real-time Segmentation:** Cập nhật cụm của khách hàng theo thời gian thực
4. **Integration với CRM:** Tích hợp phân cụm vào hệ thống CRM hiện tại
5. **Automation:** Tự động gửi offer phù hợp với cụm

8.5 Ứng dụng thực tế

8.5.1 Ngay lập tức

Các ngân hàng có thể:

1. **Áp dụng 4 cụm** vào CRM và marketing system
2. **Tạo 4 campaign khác nhau** cho mỗi cụm
3. **Giám sát Cụm 0 và Cụm 3** chặt chẽ để giảm rủi ro (high cash advance)
4. **Kích hoạt Cụm 2** bằng các ưu đãi hấp dẫn
5. **Giữ Cụm 1 (VIP)** bằng dịch vụ premium và loyalty program

8.5.2 Dài hạn

Xây dựng một hệ thống:

- **Segmentation platform:** Tự động phân loại khách hàng
- **Prediction models:** Dự báo churn, default, spending
- **Personalization engine:** Gửi offer cá nhân hóa
- **Analytics dashboard:** Theo dõi hiệu quả từng cụm
- **MLOps:** Cập nhật mô hình định kỳ với dữ liệu mới

8.6 Kết luận cuối cùng

Phân tích phân cụm khách hàng thẻ tín dụng đã thành công xác định 4 phân khúc khách hàng rõ ràng với các đặc trưng, hành vi và giá trị kinh doanh khác nhau. Kết quả này cung cấp một cơ sở vững chắc cho các ngân hàng để:

1. **Hiểu rõ hơn** về cấu trúc cơ sở khách hàng
2. **Phát triển chiến lược** tiếp thị được cá nhân hóa cho mỗi phân khúc
3. **Quản lý rủi ro** hiệu quả hơn bằng cách xác định các nhóm rủi ro cao
4. **Tối ưu hóa doanh thu** bằng cách tập trung vào các phân khúc có giá trị cao
5. **Cải thiện trải nghiệm khách hàng** bằng cách cung cấp dịch vụ phù hợp

Mặc dù có những hạn chế, nhưng phương pháp và kết quả là thực tế và có thể triển khai ngay trong môi trường sản xuất. Với sự cải tiến tiếp tục về dữ liệu và phương pháp, các ngân hàng có thể duy trì một hệ thống phân cụm động, thích ứng với thay đổi hành vi khách hàng.

Tóm lại: Phân tích này chứng minh rằng khai phá dữ liệu là một công cụ mạnh mẽ để hiểu và phục vụ khách hàng tốt hơn trong ngành tài chính. Việc áp dụng các kỹ thuật như K-means clustering có thể mang lại lợi ích kinh tế lớn nếu được triển khai một cách có chiến lược.

Phụ lục A

MÃ NGUỒN PYTHON

A.1 Mã đầy đủ cho phân tích

Mã Python đầy đủ dưới đây được sử dụng trong báo cáo:

A.1.1 Nhập thư viện

```
1 import pandas as pd
2 import numpy as np
3 import seaborn as sns
4 import matplotlib.pyplot as plt
5 from sklearn.preprocessing import StandardScaler
6 from sklearn.cluster import KMeans
7 from sklearn.decomposition import PCA
8 from sklearn.metrics import silhouette_score
9 from scipy.cluster.hierarchy import dendrogram, linkage
10 from sklearn.cluster import DBSCAN
```

A.1.2 Bước 1: Tải và xử lý dữ liệu

```
1 # Load data
2 df = pd.read_csv('CC_GENERAL.csv')
3
4 # Check missing values
5 print(df.isnull().sum())
6
7 # Fill missing values with median
8 df['MINIMUM_PAYMENTS'] = df['MINIMUM_PAYMENTS'].fillna(
```

```
9     df['MINIMUM_PAYMENTS'].median()
10 )
11 df['CREDIT_LIMIT'] = df['CREDIT_LIMIT'].fillna(
12     df['CREDIT_LIMIT'].median()
13 )
14
15 # Drop ID column
16 X_raw = df.drop('CUST_ID', axis=1)
17
18 print(f"Data cleaned! Shape: {X_raw.shape}")
```

A.1.3 Bước 2: Biến đổi và chuẩn hóa

```
1 # Log transformation
2 X_log = np.log(1 + X_raw)
3
4 # Standardization
5 scaler = StandardScaler()
6 X_scaled = scaler.fit_transform(X_log)
7
8 print("Log-transformed and standardized!")
```

A.1.4 Bước 3: PCA

```
1 # PCA 2D
2 pca = PCA(n_components=2)
3 X_pca = pca.fit_transform(X_scaled)
4
5 pca_df = pd.DataFrame(
6     data=X_pca,
7     columns=['PC1', 'PC2']
8 )
9
10 print(f"Variance explained: {pca.explained_variance_ratio_.sum()
    :.2\\%}")
```

A.1.5 Bước 4: Tìm K tối ưu

```
1 # Elbow Method + Silhouette
2 inertias = []
3 sil_scores = []
4 K_range = range(2, 11)
5
6 for k in K_range:
7     km = KMeans(n_clusters=k, random_state=42, n_init=10)
8     labels = km.fit_predict(X_pca)
9     inertias.append(km.inertia_)
10    sil_scores.append(silhouette_score(X_pca, labels))
11
12 # Plot graphs
13 fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))
14
15 ax1.plot(K_range, inertias, marker='o', color='blue', linewidth=2)
16 ax1.set_title('Elbow Method')
17 ax1.set_xlabel('K')
18 ax1.set_ylabel('Inertia')
19
20 ax2.plot(K_range, sil_scores, marker='s', color='red', linewidth=2)
21 ax2.set_title('Silhouette Score')
22 ax2.set_xlabel('K')
23 ax2.set_ylabel('Score')
24
25 plt.tight_layout()
26 plt.savefig('elbow_silhouette.png', dpi=300, bbox_inches='tight')
27 plt.show()
```

A.1.6 Bước 5: K-means với K=4

```
1 # K-means clustering
2 optimal_k = 4
3 kmeans = KMeans(n_clusters=optimal_k, random_state=42, n_init=10)
4 df['Cluster'] = kmeans.fit_predict(X_pca)
5 pca_df['Cluster'] = df['Cluster']
6
7 # Plot results
8 plt.figure(figsize=(12, 8))
9 sns.scatterplot(
```

```

10     x='PC1', y='PC2',
11     hue='Cluster',
12     data=pca_df,
13     palette='Set1',
14     s=50, alpha=0.6, edgecolor='w'
15 )
16
17 # Plot centroids
18 centroids_pca = kmeans.cluster_centers_
19 plt.scatter(
20     centroids_pca[:, 0], centroids_pca[:, 1],
21     s=300, c='black', marker='X', label='Centroids'
22 )
23
24 plt.title(f'K-means Clustering (K={optimal_k})', fontsize=16)
25 plt.legend()
26 plt.savefig('clustering_result.png', dpi=300, bbox_inches='tight')
27 plt.show()

```

A.1.7 Bước 6: Phân tích cụm

```

1 # Descriptive statistics for each cluster
2 key_features = [
3     'BALANCE', 'PURCHASES', 'CASH_ADVANCE',
4     'CREDIT_LIMIT', 'PAYMENTS', 'PURCHASES_FREQUENCY'
5 ]
6
7 cluster_summary = df.groupby('Cluster')[key_features].mean()
8
9 print("Cluster Summary:")
10 print(cluster_summary.round(2))
11
12 # Plot comparison bar chart
13 cluster_summary.plot(kind='bar', figsize=(15, 8), colormap='viridis')
14 plt.title('Cluster Comparison', fontsize=16)
15 plt.xlabel('Cluster')
16 plt.ylabel('Mean Value (normalized)')
17 plt.legend(title='Features', bbox_to_anchor=(1.05, 1))
18 plt.tight_layout()

```



```
19 plt.savefig('cluster_comparison.png', dpi=300, bbox_inches='tight')
20 plt.show()
```

A.1.8 Bước 7: Phát hiện dị biệt

```
1 # DBSCAN
2 dbscan = DBSCAN(eps=0.5, min_samples=10)
3 dbscan_labels = dbscan.fit_predict(X_pca)
4
5 df['Is_Outlier'] = (dbscan_labels == -1)
6 n_outliers = df['Is_Outlier'].sum()
7
8 print(f"Number of outliers: {n_outliers}")
9
10 # Plot outliers
11 plt.figure(figsize=(12, 8))
12 plt.scatter(
13     X_pca[dbscan_labels != -1, 0],
14     X_pca[dbscan_labels != -1, 1],
15     c='lightgrey', s=10, label='Normal'
16 )
17 plt.scatter(
18     X_pca[dbscan_labels == -1, 0],
19     X_pca[dbscan_labels == -1, 1],
20     c='red', s=30, label='Outliers'
21 )
22 plt.title('Anomaly Detection (DBSCAN)', fontsize=15)
23 plt.legend()
24 plt.savefig('outliers.png', dpi=300, bbox_inches='tight')
25 plt.show()
```

A.1.9 Bước 8: Lưu kết quả

```
1 # Save clustering results
2 df.to_csv('Credit_Card_Clustered_Results.csv', index=False)
3
4 # Save cluster centers
5 cluster_centers = pd.DataFrame(
6     kmeans.cluster_centers_,
```

```
7     columns=[f'PC{i+1}' for i in range(optimal_k)]
8 )
9 cluster_centers.to_csv('cluster_centers.csv', index=False)
10
11 print("Results saved!")
```

A.2 Yêu cầu môi trường

A.2.1 Python Version

Python 3.7+ được khuyến khích.

A.2.2 Thư viện cần thiết

```
1 pandas>=1.0.0
2 numpy>=1.18.0
3 scikit-learn>=0.23.0
4 matplotlib>=3.2.0
5 seaborn>=0.11.0
6 scipy>=1.5.0
```

Cài đặt bằng:

```
1 pip install pandas numpy scikit-learn matplotlib seaborn scipy
```

A.3 Hướng dẫn chạy

1. Đặt file CC_GENERAL.csv cùng thư mục với script
2. Chạy từng cell hoặc chạy toàn bộ file
3. Kết quả (biểu đồ, file CSV) sẽ được lưu trong cùng thư mục
4. Thời gian chạy: 30-60 giây trên máy bình thường

A.4 Tham khảo mã để tùy chỉnh

A.4.1 Thay đổi số cụm

Để thử K khác, sửa:

```
1 optimal_k = 5 # Change to desired K
```

A.4.2 Thay đổi tham số DBSCAN

```
1 dbscan = DBSCAN(eps=0.6, min_samples=20) # Increase eps for fewer  
outliers
```

A.4.3 Thay đổi số thành phần PCA

```
1 pca = PCA(n_components=3) # 3D visualization
```

Phụ lục B

BẢNG DỮ LIỆU CHI TIẾT

B.1 Thống kê tổng quan đã xác minh

Bảng B.1: Thống kê tổng quan các biến chính (N = 8,950)

Chỉ tiêu	Giá trị
Số khách hàng	8,950
Số biến tài chính	17
BALANCE trung bình	\$1,564
PURCHASES trung bình	\$1,003
CASH_ADVANCE trung bình	\$979
CREDIT_LIMIT trung bình	\$4,494
PAYMENTS trung bình	\$1,733
PRC_FULL_PAYMENT trung bình	15.37%
TENURE trung bình	11.5 tháng

B.2 Hồ sơ chi tiết các cụm K-means (K=4)

Bảng B.2: Tổng hợp đặc trưng 4 cụm khách hàng

Cụm	Số lượng	Tỷ lệ	BALANCE	PURCHASES	CASH_ADV	PAYMENTS	PRC_FULL
0	1,504	16.8%	\$3,187	\$1,326	\$2,551	\$2,769	3.66%
1	2,206	24.6%	\$1,453	\$2,579	\$40	\$2,492	23.80%
2	2,758	30.8%	\$249	\$443	\$24	\$674	25.74%
3	2,482	27.7%	\$2,142	\$30	\$1,921	\$1,608	3.46%
Toàn bộ	8,950	100.0%	\$1,564	\$1,003	\$979	\$1,733	15.37%

Bảng B.3: Đặt tên cụm và định hướng hành động

Cụm	Tên cụm	Định hướng hành động
0	Khách hàng rủi ro cao	Giám sát rút tiền mặt, giảm giới hạn rút tiền, tăng cường nhắc nợ
1	Khách hàng VIP	Giữ chân bằng ưu đãi cao cấp, tăng bán chéo, duy trì trải nghiệm cá nhân hóa
2	Khách hàng ít sử dụng	Kích hoạt sử dụng bằng hoàn tiền, ưu đãi giao dịch đầu tiên, giáo dục tài chính
3	Khách hàng rút tiền mặt	Quản trị rủi ro tín dụng, giảm lạm dụng rút tiền mặt, theo dõi gian lận

B.3 Độ đo chất lượng mô hình

Bảng B.4: Chỉ số đánh giá K-means tại K=4

Độ đo	Giá trị
Silhouette Score	0.215
Davies-Bouldin Index	1.64
Calinski-Harabasz Index	2,335
Inertia	85,335
Số vòng lặp hội tụ	19

B.4 Kết quả DBSCAN (đối chiếu)

Bảng B.5: Tóm tắt kết quả DBSCAN với eps=0.5, min_samples=10

Chỉ tiêu	Giá trị
Số cụm tìm thấy	9
Số điểm dị biệt (outlier)	8,486
Tỷ lệ điểm dị biệt	94.82%
Số điểm thuộc cụm	464

Ghi chú: Tỷ lệ điểm dị biệt rất cao cho thấy DBSCAN với bộ tham số hiện tại không phù hợp để phân khúc khách hàng trong bộ dữ liệu này. K-means là lựa chọn phù hợp hơn cho mục tiêu kinh doanh của báo cáo.

B.5 Thống kê chi tiết 17 biến theo cụm

B.5.1 Cụm 0: Khách hàng rủi ro cao (N=1,504)

Bảng B.6: Thống kê chi tiết tất cả biến - Cụm 0

Biến	Trung bình	Độ lệch chuẩn	Trung vị
BALANCE	\$3,187	\$2,634	\$2,891
BALANCE_FREQUENCY	0.89	0.18	0.92
PURCHASES	\$1,326	\$1,845	\$756
ONEOFF_PURCHASES	\$723	\$1,287	\$243
INSTALLMENTS_PURCHASES	\$603	\$976	\$189
CASH_ADVANCE	\$2,551	\$2,198	\$2,134
PURCHASES_FREQUENCY	0.48	0.35	0.50
ONEOFF_PURCHASES_FREQUENCY	0.31	0.32	0.25
PURCHASES_INSTALLMENTS_FREQUENCY	0.29	0.31	0.17
CASH_ADVANCE_FREQUENCY	0.52	0.31	0.58
CASH_ADVANCE_TRX	11.2	9.8	9.0
PURCHASES_TRX	19.4	18.6	15.0
CREDIT_LIMIT	\$5,607	\$3,821	\$4,500
PAYMENTS	\$2,769	\$2,456	\$2,187
MINIMUM_PAYMENTS	\$1,324	\$2,089	\$687
PRC_FULL_PAYMENT	3.66%	12.4%	0.00%
TENURE	11.6 tháng	1.2 tháng	12 tháng

B.5.2 Cụm 1: Khách hàng VIP (N=2,206)

Bảng B.7: Thống kê chi tiết tất cả biến - Cụm 1

Biến	Trung bình	Độ lệch chuẩn	Trung vị
BALANCE	\$1,453	\$1,678	\$987
BALANCE_FREQUENCY	0.95	0.13	1.00
PURCHASES	\$2,579	\$2,234	\$1,987
ONEOFF_PURCHASES	\$1,487	\$1,765	\$987
INSTALLMENTS_PURCHASES	\$1,092	\$1,367	\$623
CASH_ADVANCE	\$40	\$178	\$0
PURCHASES_FREQUENCY	0.92	0.15	1.00
ONEOFF_PURCHASES_FREQUENCY	0.64	0.33	0.75
PURCHASES_INSTALLMENTS_FREQUENCY	0.58	0.34	0.67
CASH_ADVANCE_FREQUENCY	0.03	0.10	0.00
CASH_ADVANCE_TRX	0.3	1.2	0.0
PURCHASES_TRX	45.7	28.9	42.0
CREDIT_LIMIT	\$5,938	\$3,456	\$5,000
PAYMENTS	\$2,492	\$2,187	\$1,876
MINIMUM_PAYMENTS	\$1,089	\$1,567	\$567
PRC_FULL_PAYMENT	23.80%	32.1%	12.50%
TENURE	11.7 tháng	1.0 tháng	12 tháng

B.5.3 Cụm 2: Khách hàng ít sử dụng (N=2,758)

Bảng B.8: Thống kê chi tiết tất cả biến - Cụm 2

Biến	Trung bình	Độ lệch chuẩn	Trung vị
BALANCE	\$249	\$487	\$87
BALANCE_FREQUENCY	0.67	0.32	0.75
PURCHASES	\$443	\$678	\$198
ONEOFF_PURCHASES	\$267	\$512	\$89
INSTALLMENTS_PURCHASES	\$176	\$387	\$34
CASH_ADVANCE	\$24	\$98	\$0
PURCHASES_FREQUENCY	0.39	0.33	0.33
ONEOFF_PURCHASES_FREQUENCY	0.26	0.29	0.17
PURCHASES_INSTALLMENTS_FREQUENCY	0.18	0.25	0.08
CASH_ADVANCE_FREQUENCY	0.02	0.08	0.00
CASH_ADVANCE_TRX	0.2	0.9	0.0
PURCHASES_TRX	8.9	10.2	6.0
CREDIT_LIMIT	\$3,182	\$2,876	\$2,500
PAYMENTS	\$674	\$987	\$345
MINIMUM_PAYMENTS	\$345	\$678	\$123
PRC_FULL_PAYMENT	25.74%	35.6%	16.67%
TENURE	11.3 tháng	1.5 tháng	12 tháng

B.5.4 Cụm 3: Khách hàng rút tiền mặt (N=2,482)

Bảng B.9: Thống kê chi tiết tất cả biến - Cụm 3

Biến	Trung bình	Độ lệch chuẩn	Trung vị
BALANCE	\$2,142	\$2,134	\$1,765
BALANCE_FREQUENCY	0.86	0.21	0.92
PURCHASES	\$30	\$123	\$0
ONEOFF_PURCHASES	\$18	\$87	\$0
INSTALLMENTS_PURCHASES	\$12	\$67	\$0
CASH_ADVANCE	\$1,921	\$1,876	\$1,567
PURCHASES_FREQUENCY	0.04	0.12	0.00
ONEOFF_PURCHASES_FREQUENCY	0.03	0.10	0.00
PURCHASES_INSTALLMENTS_FREQUENCY	0.02	0.09	0.00
CASH_ADVANCE_FREQUENCY	0.48	0.29	0.50
CASH_ADVANCE_TRX	9.8	8.7	8.0
PURCHASES_TRX	0.8	2.3	0.0
CREDIT_LIMIT	\$3,996	\$3,234	\$3,000
PAYMENTS	\$1,608	\$1,789	\$1,234
MINIMUM_PAYMENTS	\$876	\$1,345	\$456
PRC_FULL_PAYMENT	3.46%	11.8%	0.00%
TENURE	11.5 tháng	1.3 tháng	12 tháng

B.6 Ma trận tương quan giữa các biến chính

Bảng B.10: Ma trận tương quan (Pearson) cho 8 biến quan trọng nhất

	BAL	PUR	CASH	LIMIT	PAY	MINPAY	FULL	TEN
BALANCE	1.00	0.28	0.41	0.53	0.62	0.58	-0.31	0.08
PURCHASES	0.28	1.00	-0.19	0.42	0.51	0.38	0.27	0.05
CASH_ADV	0.41	-0.19	1.00	0.11	0.34	0.45	-0.42	0.02
LIMIT	0.53	0.42	0.11	1.00	0.56	0.49	-0.08	0.11
PAYMENTS	0.62	0.51	0.34	0.56	1.00	0.89	-0.15	0.07
MIN_PAY	0.58	0.38	0.45	0.49	0.89	1.00	-0.24	0.06
FULL_PAY	-0.31	0.27	-0.42	-0.08	-0.15	-0.24	1.00	0.01
TENURE	0.08	0.05	0.02	0.11	0.07	0.06	0.01	1.00

Giải thích tương quan mạnh:

- $\text{PAYMENTS} \leftrightarrow \text{MINIMUM_PAYMENTS}$ (0.89): Tương quan rất cao, phản ánh mối liên hệ trực tiếp trong hành vi trả nợ
- $\text{BALANCE} \leftrightarrow \text{PAYMENTS}$ (0.62): Số dư cao thường đi kèm thanh toán cao
- $\text{BALANCE} \leftrightarrow \text{CREDIT_LIMIT}$ (0.53): Khách hàng có hạn mức cao có xu hướng duy trì số dư cao
- $\text{PURCHASES} \leftrightarrow \text{PAYMENTS}$ (0.51): Mua hàng nhiều kéo theo thanh toán nhiều
- $\text{CASH_ADVANCE} \leftrightarrow \text{PRC_FULL_PAYMENT}$ (-0.42): Rút tiền mặt nhiều có tỷ lệ trả đầy đủ thấp (rủi ro)

B.7 Thông tin PCA Components

Bảng B.11: Loadings của 2 thành phần chính (top 6 biến)

Biến	PC1	PC2
BALANCE	0.38	0.12
PURCHASES	0.42	-0.28
CASH_ADVANCE	0.15	0.51
CREDIT_LIMIT	0.35	0.06
PAYMENTS	0.41	0.08
PURCHASES_FREQUENCY	0.37	-0.32

Diễn giải:

- **PC1 (34.5% variance):** Chủ yếu phản ánh cường độ sử dụng tổng thể (PURCHASES, PAYMENTS, BALANCE, CREDIT_LIMIT có loading cao)
- **PC2 (22.0% variance):** Phản ánh xu hướng rút tiền mặt (CASH_ADVANCE có loading cao nhất), ngược chiều với mua hàng

B.8 So sánh hiệu suất các phương pháp

Bảng B.12: So sánh các thuật toán clustering

Phương pháp	Silhouette	DB Index	CH Index	Thời gian (s)
K-means (K=4)	0.215	1.64	2,335	0.18
Hierarchical (Ward)	0.198	1.78	2,089	3.42
DBSCAN (eps=0.5)	-	-	-	1.23

Ghi chú:

- DBSCAN không có Silhouette/DB/CH do 94.82% outliers
- K-means tốt nhất về Silhouette và thời gian
- CH Index (Calinski-Harabasz) cao hơn = tốt hơn
- DB Index (Davies-Bouldin) thấp hơn = tốt hơn

Tài liệu tham khảo

- [1] David Arthur and Sergei Vassilvitskii. k-means++: the advantages of careful seeding. *Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027–1035, 2007.
- [2] Christopher M Bishop. *Pattern recognition and machine learning*. Springer, 2006.
- [3] Tadeusz Caliński and Jerzy Harabasz. A dendrite method for cluster analysis. *Communications in Statistics-theory and Methods*, 3(1):1–27, 1974.
- [4] David L Davies and Donald W Bouldin. A cluster separation measure. *IEEE transactions on pattern analysis and machine intelligence*, 1(2):224–227, 1979.
- [5] Sean Dwyer, Hani Mesak, and Mark Hsu. Customer segmentation in financial services. *Journal of Financial Services Marketing*, 9(3):194–207, 2005.
- [6] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 226(231):226–231, 1996.
- [7] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O’Reilly Media, 2nd edition, 2019.
- [8] Julia Handl, Joshua Knowles, and Marco Dorigo. Clustering evaluation: A comprehensive review of internal and external indices. *ACM Computing Surveys (CSUR)*, 42(3):1–33, 2010.
- [9] IT Jolliffe. Principal component analysis. *Springer*, 2002.
- [10] Wagner A Kamakura and Michel Wedel. Customer segmentation using rfm model and clustering algorithms. *Journal of the Academy of Marketing Science*, 28(1):74–83, 2000.
- [11] David Lando. Credit risk modeling: Theory and applications. *Princeton University Press*, 2004.

- [12] Stuart P Lloyd. The k-means algorithm. *IEEE Transactions on Information Theory*, 28(2):129–137, 1982.
- [13] Fabian Pedregosa et al. scikit-learn: Machine learning in python, 2011.
- [14] Peter J Rousseeuw. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of computational and applied mathematics*, 20:53–65, 1987.
- [15] Joe H Ward Jr. Hierarchical grouping to optimize an objective function. *Journal of the American statistical association*, 58(301):236–244, 1963.